

EEGNet

EEGNet: A Compact Convolutional Neural Network for EEG-based Brain-Computer Interfaces

Vernon J. Lawhern^{1,*}, Amelia J. Solon^{1,2}, Nicholas R. Waytowich^{1,3}, Stephen M. Gordon^{1,2},
Chou P. Hung^{1,4}, and Brent J. Lance¹

¹Human Research and Engineering Directorate, U.S. Army Research Laboratory, Aberdeen
Proving Ground, MD

²DCS Corporation, Alexandria, VA

³Department of Biomedical Engineering, Columbia University, New York, NY

⁴Department of Neuroscience, Georgetown University, Washington, DC

*Corresponding Author

May 17, 2018

<https://arxiv.org/pdf/1611.08024>

<https://github.com/vlawhern/arl-eegmodels>

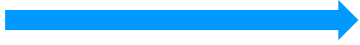

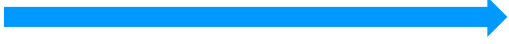


- 특정 EEG task에 특화된 딥러닝 모델이 아닌, 범용 EEG 딥러닝 모델
- 파라미터 수를 줄인 딥러닝 모델
- 설명가능한 딥러닝 모델



Introduction

BCI의 주요 처리 단계

1. 뇌 신경 데이터를 기록하는 **데이터 수집** 단계
2. 기록된 데이터를 전처리하고 정제하는 **신호 처리** 단계 
3. 신경 데이터에서 유의미한 정보를 추출하는 **특징 추출** 단계  수동 설정
4. 데이터를 기반으로 판단을 내리는 **분류** 단계 
5. 그 결과를 사용자에게 **전달**하는 피드백 단계

- 해당분야 전문 지식, 예상되는 EEG 신호에 대한 사전 지식 필요
- 신호처리 단계에서 필터링 할 때, 주파수 범위를 벗어나는 잠재적으로 유의미한 신호가 EEG 특징 분석에서 제외될 수 있음.



Introduction

- 이 논문 이전에도, EEG 데이터를 CNN을 사용하여 분류하고자 하는 여러 연구가 있다.
- 이들 연구는 대부분 하나의 BCI 작업에만 특화
- 작업에 특화된 지식을 바탕으로 네트워크 구조 설계
- 데이터 양도 연구마다 상당히 다름

=> 이전의 딥러닝 접근법들은 다양한 학습 데이터 크기에서 일반화 불확실



Introduction

1. 다양한 BCI 패러다임에서 범용적으로 작동하는 모델
2. 소량의 데이터로도 학습 가능한 간결한 모델 구조
3. 신경생리학적으로 해석 가능한 특징 학습



Materials and Methods

BCI type

1. ERP(Event-Related Potential)

2. Oscillatory

구분	ERP BCI	Oscillatory BCI
신호 특징	시간 자극에 고정된 강한 반응 (낮은 주파수, 높은 진폭)	특정 주파수 대역의 EEG 파워
특징	반복적, 안정적, 피험자 간 일관성 높음	비동기적, 노이즈 많고 피험자 간 다양성 큼
분석 방식	ERP 파형 검출	ERSP 분석 가능
훈련 난이도	상대적으로 쉬움	상대적으로 어려움
구분	ERP BCI	Oscillatory BCI



Materials and Methods

Paradigm	Feature Type	Bandpass Filter	# of Subjects	Trials per Subject	# of Classes	Class Imbalance?
P300	ERP	1-40Hz	15	~ 2000	2	Yes, ~ 5.6:1
ERN	ERP	1-40Hz	26	340	2	Yes, ~ 3.4:1
MRCP	ERP/Oscillatory	0.1-40Hz	13	~ 1100	2	No
SMR	Oscillatory	4-40Hz	9	288	4	No

P300과 ERN은 ERP 기반이며 클래스 불균형이 존재함.

MRCP는 ERP와 Oscillatory 특성을 모두 가짐.

SMR은 순수 Oscillatory 기반이고 4개의 클래스를 가짐.



Materials and Methods

P300

두정엽(parietal cortex) 부위에서 관찰되며, 자극 후 약 300ms 시점에 강한 양의 전기 신호 변화

타겟이 드물수록 P300 반응은 강하게 나타남.

자극 제시 속도가 2Hz 이상이면 **RSVP(빠른 연속 시각 제시)** 라고 하며,
이는 이미지 분류용 BCI에 널리 사용됨.

Target : 자동차 또는 사람 포함된 사진

Non-target : 자동차 또는 사람이 없는 사진

=> Target이미지에서 버튼을 누르도록 지시함. 1초에 2장씩 제시.



Materials and Methods

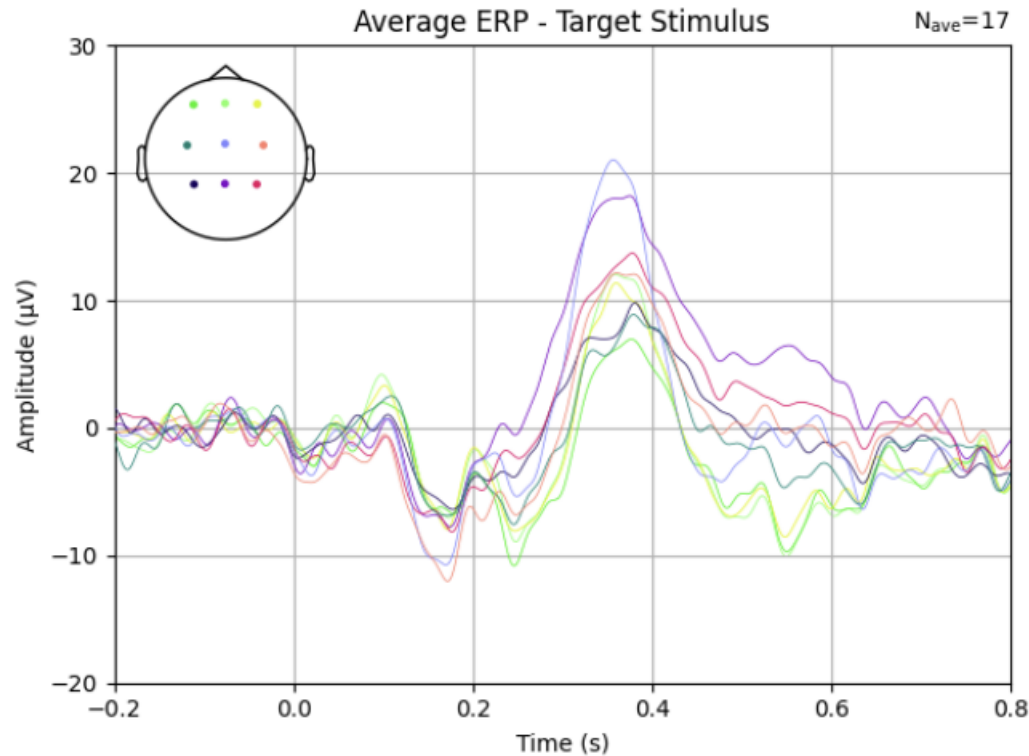


Figure 1: The average P300 as evoked from the sample data.




Figure 2: The average EEG response to the target (blue) and non-target (orange) of the Cz electrode.



Materials and Methods

항목	설명
Paradigm	Visual Oddball (RSVP)
자극 조건	2Hz로 이미지 제시, Target : Non-Target = 1:4 (20%:80%)
참가자 수	총 18명 중 15명 데이터 사용
EEG 채널 수	64채널, 10-10 시스템
Sampling Rate	원본 512 Hz → 128 Hz로 다운샘플링
Filter	1–40 Hz FIR Bandpass 필터
추출 구간	자극 이후 0~1초
클래스 수	2 (target vs. non-target)


양쪽 귓볼 평균값을 기준 전위로 삼아 재정렬



ERN(Feedback Error-Related Negativity)

피험자가 실수하거나 예상치 못한 상황에 직면했을 때 EEG에 나타나는 변동

Feedback ERN은 보통 자극(피드백) 이후 350ms에 나타나는 음의 전위,
500ms쯤에 나타나는 양의 전위로 구성.





Materials and Methods

항목	설명
Paradigm	P300 Speller + Feedback ERN
자극 유형	피드백에 대한 오류 인식 (정답/오답)
참가자 수	총 26명 (훈련: 16명, 테스트: 10명)
채널 수	56채널 (Ag/AgCl 전극, 10-20 확장 시스템)
Sampling Rate	원본 600Hz → 128Hz로 다운샘플링
Filter	1-40 Hz FIR 필터 (EEGLAB 사용)
추출 구간	피드백 이후 0~1.25초
클래스 수	2 (정답 피드백 vs. 오답 피드백)

데이터는 Kaggle에서 주최한 **BCI Challenge** 대회에서 사용된 데이터

=> 총 26명의 건강한 참가자가 P300 스펠러 과제에 참여했으며, 이는 무작위로 깜빡이는 6×6 글자 배열을 사용하여 P300 반응을 유도하는 시스템.

<https://www.kaggle.com/c/inria-bci-challenge>



MRCP(Movement-Related Cortical Potential)

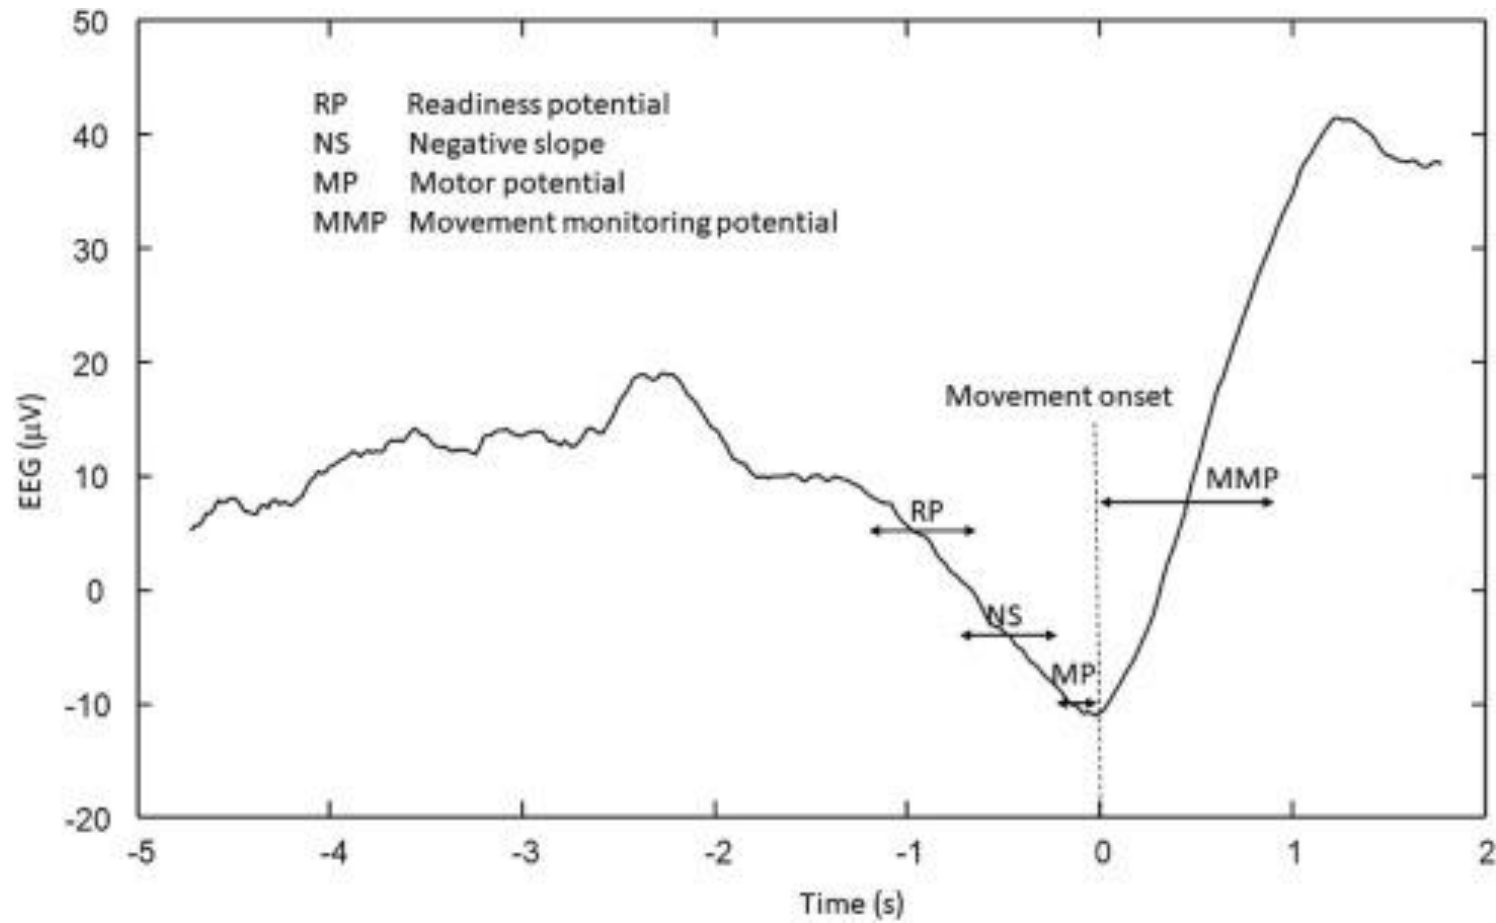
손과 발의 자발적 움직임에 의해 유도되며, 움직인 쪽과 반대쪽 대뇌 반구에서 관찰

시간대	특징	주파수 대역
움직이기 전	Readiness potential (느린 증가 신호), 10–12Hz desynchronization	0–5Hz, 10–12Hz
움직이는 순간	Slow motor potential (느린 운동 전위)	
움직인 후 약 1초	20–30Hz 재동기화(synchronization)	20–30Hz

구간	뇌파 반응	ERP or Oscillatory?	주파수대
운동 이전	준비 전위 (readiness potential)	ERP	~0–5Hz
운동 이전	초기 비동기화 (desynchronization, ERD)	Oscillatory	10–12Hz
운동 시작	느린 운동 전위 (slow motor potential)	ERP	저주파 (~0–5Hz)
운동 이후	늦은 동기화 (late synchronization, ERS)	Oscillatory	20–30Hz




Materials and Methods





Materials and Methods

항목	설명
Paradigm	Self-paced finger movement
신호 특징	ERP + Oscillatory (혼합)
참가자 수	13명
채널 수	원래 256채널 → 64채널 다운샘플링
Sampling Rate	원본 1024Hz → 128Hz로 다운샘플링
Filter	0.1–40 Hz FIR 필터 (EEGLAB)
Reference	Linked mastoids
추출 구간	움직임 기준 -0.5초 ~ +1초
클래스 수	2 (왼손 vs 오른손 손가락 움직임)





Materials and Methods

SMR(Sensory Motor Rhythm)

실제 또는 상상된 움직임이 있을 때, 반대쪽 운동 피질(sensorimotor cortex) 영역에서 mu파와 beta파가 비동기화(desynchronization)

MRCP의 진동 성분과 매우 유사

SMR 신호는 약하고, 피험자 간/내 변동성이 큼 → 따라서 사용자 훈련(neurofeedback) 과 긴 교정 시간(보통 20분 이상) 이 필요

Neurofeedback(신경 피드백)

뇌파 패턴이 뚜렷하게 나타나지 않거나, 개인차가 큼

→ 실시간으로 피드백을 보면서 반복 학습을 통해 신경 활동을 의도적으로 조절하는 훈련이 필요함.

Calibration Time (긴 교정 시간)

노이즈가 많고 약함, 여러 조건에 대해 반복적으로 데이터를 수집해야함.



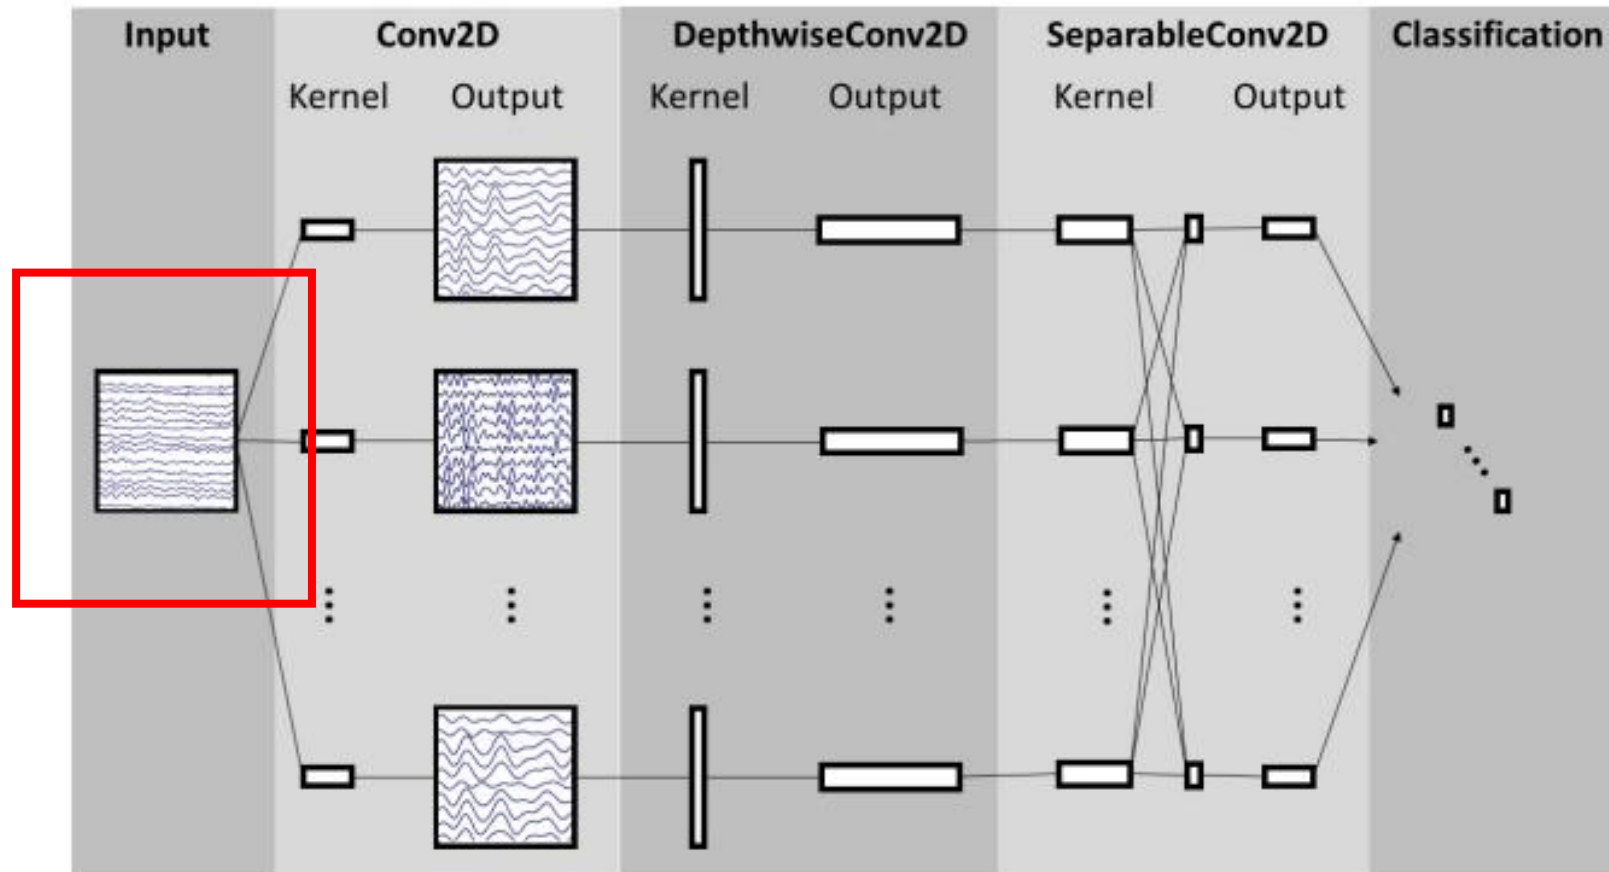
Materials and Methods

항목	내용
뇌파 종류	SMR (μ : 8–12Hz, β : 18–26Hz)
측정 조건	상상된 움직임 4종류 (왼손, 오른손, 발, 혀)
참가자 수	9명
전극 수	22채널
원래 샘플링 속도	250Hz
전처리	0.5–100Hz 필터링 → 128Hz 재샘플링
사용 시간 구간	자극 후 0.5초 ~ 2.5초
분류	4클래스 분류 (정확도 기반)

4 클래스를 이진 분류 task로 바꿔서 사용
One-vs-Rest 방식으로 바꿈




Materials and Methods





Materials and Methods



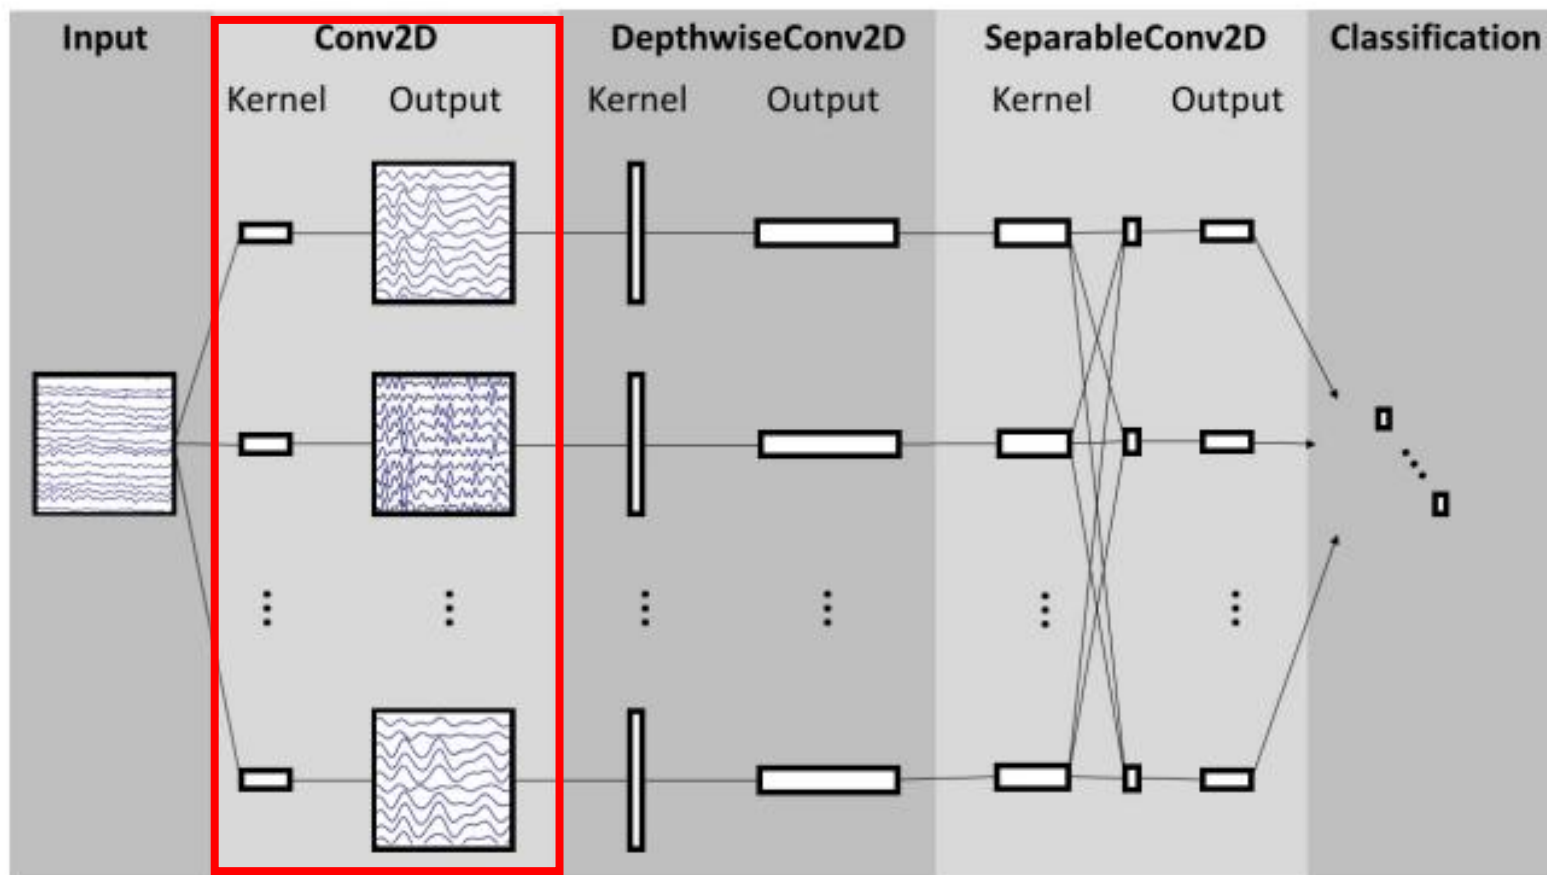
https://www.researchgate.net/figure/A-normal-EEG-reading-obtained-during-the-initial-assessment-of-the-patient-EEG_fig1_379789829

Size = (C, T) = (채널 수, 시간 요소)

- 일반적으로 CNN 용어에서 사용하는 채널 수와 다른 용어
- 머리에 꽂은 장치 수 = 채널 수
- (C, T) 흑백 이미지라고 생각하면 됨
- P300의 경우 64채널 사용 , 128Hz 1초 => 구불 구불한 선이 총 64줄, 1줄에 128개의 data point




Materials and Methods





Materials and Methods





Materials and Methods

Temporal Convolution:

Input data의 주파수는 128Hz

Conv2D 단계에서 1x64 커널 사용

1채널(1줄)의 128 data point => 65 data point => (64, 65) size

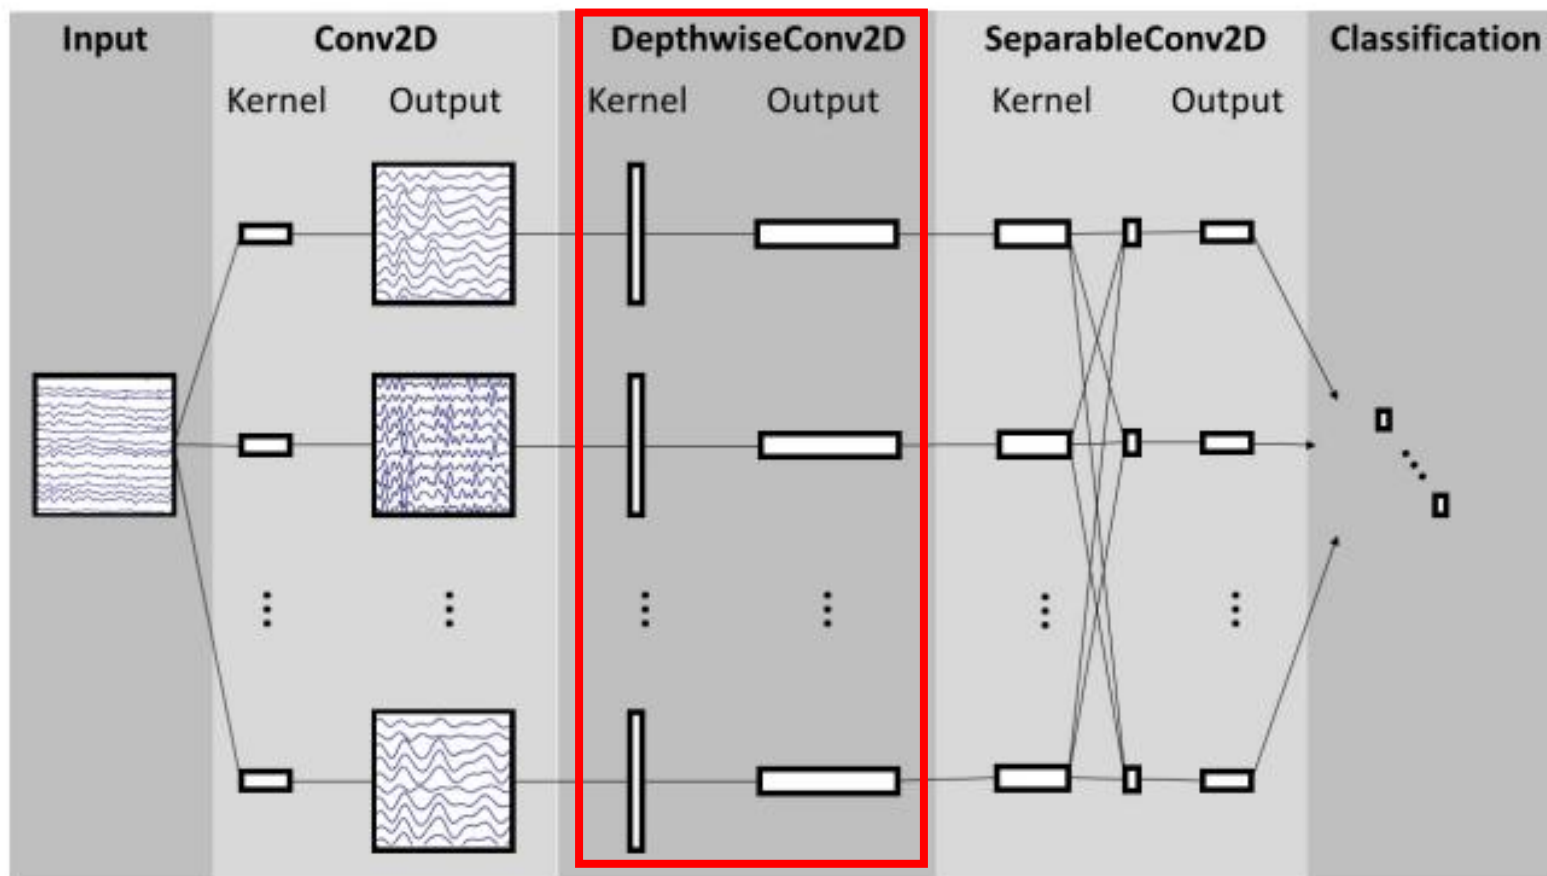
F1개 만큼 사용 => (64, 65) size가 F1개 생김

1x64커널 사용 이유 => 2Hz 이상의 주파수 정보 추출할 수 있도록

F1 = 4일 때, (64, 65) size 4개가 생김.



Materials and Methods





Materials and Methods

Depthwise Convolution:

Input size = (4, 64, 65)

커널 size = 64x1

각 주파수 필터별로 **공간 필터**를 학습 (즉, 채널 간 공간 패턴 학습)

D = 2이면, input (64, 65) 당 2개의 필터 사용
총 $F1 \cdot D (=8)$ 개의 output이 생성됨.

Outputsize = (8, 1, 65)

Average pooling

Block1: (1,4) → 샘플링 속도 32Hz

32Hz 샘플링 = 1초에 32개의 데이터 포인트

1개의 데이터 포인트 = $1000\text{ms} / 32 = 31.25\text{ms}$

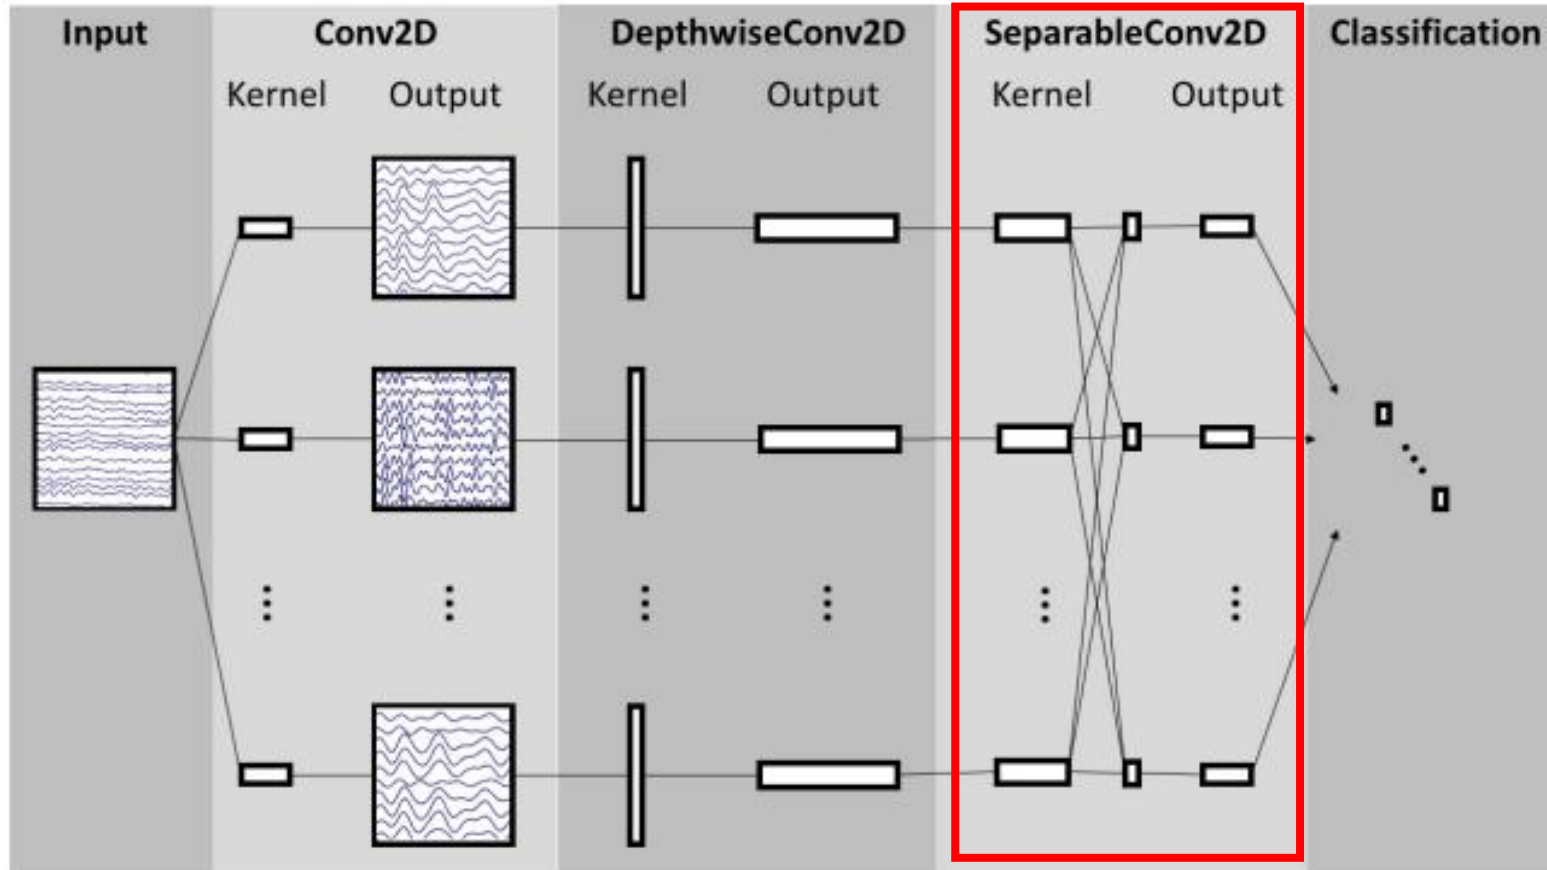
이후 Separable Conv에서 1x16 커널

1x16 커널 = $31.25\text{ms} \times 16 = 500\text{ms}$

output size = (8, 1, 16)



Materials and Methods





Materials and Methods

SeparableConv2D: 시간 요약(Depthwise) 후, feature map 간 관계 통합(Pointwise)

Depthwise Conv: (1, 16), 500ms에 해당하는 길이 (32Hz 기준)

Pointwise Conv: (1,1), 필터 수 $F2 = D \times F1$

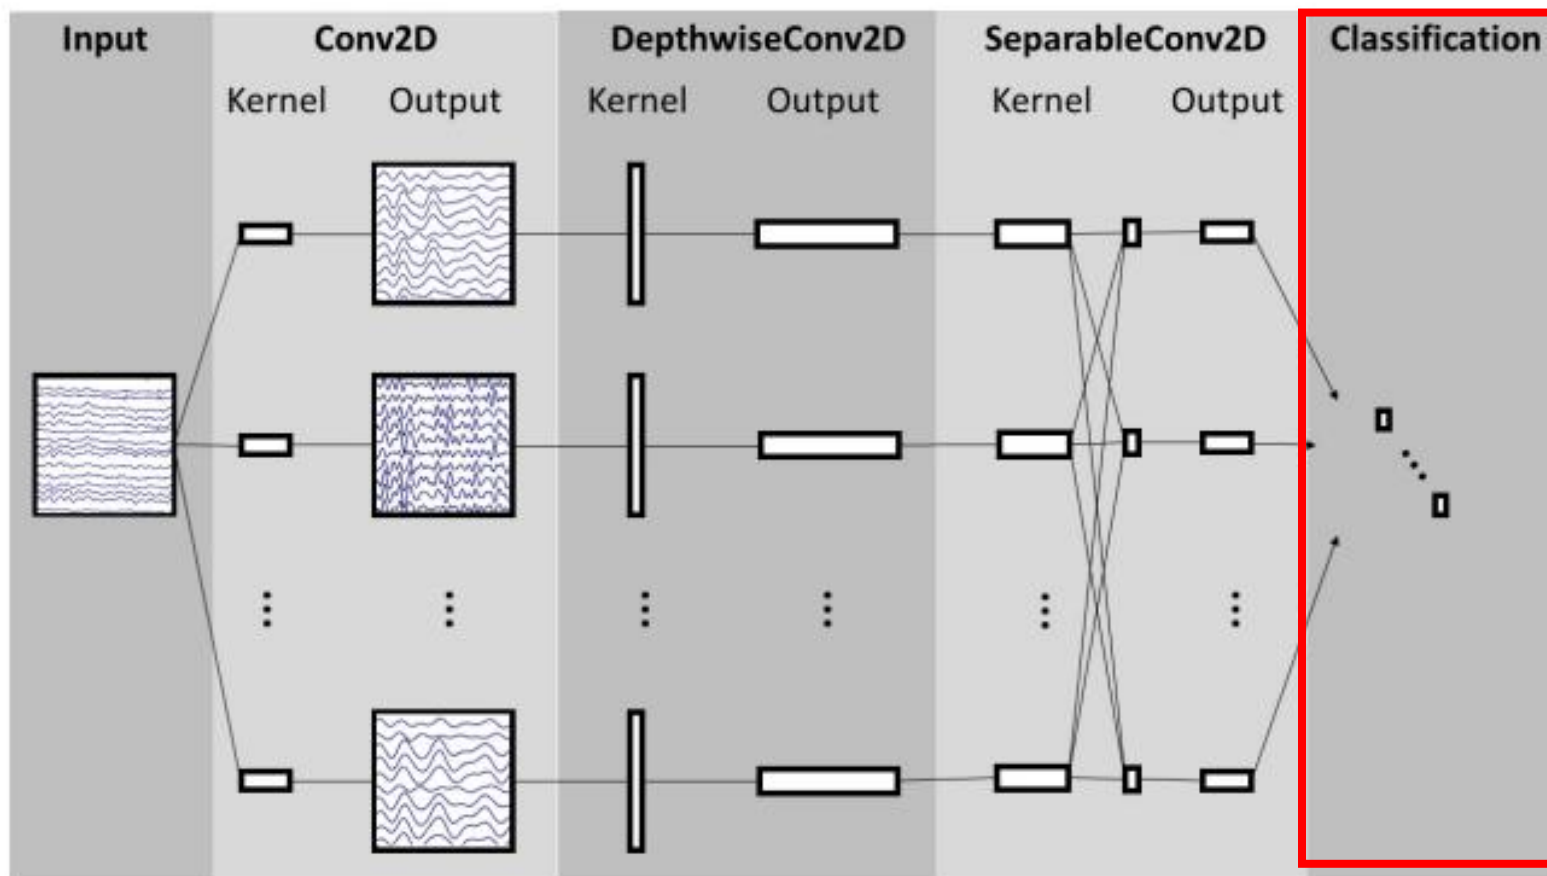
Input size = (8, 1, 16)

Kernel size = (1, 16) , 8개

Output size = (8, 1, 1)



Materials and Methods





Materials and Methods

Classifier Block

- **Flatten** 후 Softmax로 분류 (클래스 수 N)
- Fully connected 층 없이 분류



Materials and Methods

Block	Layer	# filters	size	# params	Output	Activation	Options
1	Input				(C, T)		
	Reshape				(1, C, T)		
	Conv2D	F_1	(1, 64)	$64 * F_1$	(F_1 , C, T)	Linear	mode = same
	BatchNorm			$2 * F_1$	(F_1 , C, T)		
	DepthwiseConv2D	$D * F_1$	(C, 1)	$C * D * F_1$	($D * F_1$, 1, T)	Linear	mode = valid, depth = D, max norm = 1
	BatchNorm			$2 * D * F_1$	($D * F_1$, 1, T)		
	Activation				($D * F_1$, 1, T)	ELU	
	AveragePool2D		(1, 4)		($D * F_1$, 1, T // 4)		
	Dropout*				($D * F_1$, 1, T // 4)		$p = 0.25$ or $p = 0.5$
2	SeparableConv2D	F_2	(1, 16)	$16 * D * F_1 + F_2 * (D * F_1)$	(F_2 , 1, T // 4)	Linear	mode = same
	BatchNorm			$2 * F_2$	(F_2 , 1, T // 4)		
	Activation				(F_2 , 1, T // 4)	ELU	
	AveragePool2D		(1, 8)		(F_2 , 1, T // 32)		
	Dropout*				(F_2 , 1, T // 32)		$p = 0.25$ or $p = 0.5$
	Flatten				($F_2 * (T // 32)$)		
Classifier	Dense	$N * (F_2 * T // 32)$			N	Softmax	max norm = 0.25



Materials and Methods

단계	연산	연산 설명	입력 크기 (batch_size, height, width, channels)	출력 크기
0	Input	원시 EEG 입력	(1, 1, 64, 128)	(1, 1, 64, 128)
1	Conv2D (Temporal)	(1, 64) 커널, $F_1=4$ 개, valid padding	(1, 1, 64, 128)	(1, 4, 64, 65)
2	DepthwiseConv2D (Spatial)	(64,1) 커널, $D=2 \rightarrow 4 \times 2=8$ 채널 출력	(1, 4, 64, 65)	(1, 8, 1, 65)
3	BatchNorm \rightarrow ELU \rightarrow Dropout	정규화 + 활성화 + 과적합 방지	(1, 8, 1, 65)	(1, 8, 1, 65)
4	AveragePooling (1,4)	시간축 다운샘플링 (65 \rightarrow 16)	(1, 8, 1, 65)	(1, 8, 1, 16)
5	SeparableConv2D (1,16) + (1,1)	500ms 시간요약 \rightarrow 통합	(1, 8, 1, 16)	(1, 8, 1, 1)
6	AveragePooling (1,8)	최종 차원 축소	(1, 8, 1, 1)	(1, 8, 1, 1)
7	Softmax (분류기)	Dense 생략, 바로 softmax	(1, 8, 1, 1) \rightarrow (1, 8) reshape \rightarrow softmax	(1, N)

입력 사이즈를 128hz, 1초라 가정



Materials and Methods




Figure 4: A temporal convolution and spatial convolution applied to EEG data. Image by author.

<https://medium.com/data-science/convolutional-neural-networks-for-eeeg-brain-computer-interfaces-9ee9f3dd2b81>



Materials and Methods

Parameter 수 비교

F2 = D*F1으로 진행.

	Trial Length (sec)	DeepConvNet	ShallowConvNet	EEGNet-4,2	EEGNet-8,2
P300	1	174,127	104,002	1,066	2,258
ERN	1.25	169,927	91,602	1,082	2,290
MRCP	1.5	175,727	104,722	1,098	2,322
SMR*	2	152,219	40,644	796	1,716

EEGNet-4,2
4 = F1 개수
2 = D 개수



Materials and Methods

Dropout	피험자 내 = 0.5 / 피험자 간 = 0.25
Average Pooling	Block1: (1,4) → 샘플링 속도 32Hz Block2: (1,8) → 차원 축소
정규화	Spatial filter에 대해 L2-norm 제한 ($ w _2 < 1$)
Separable Conv	(1,16) Depthwise → 500ms 요약 (1,1) Pointwise → feature 통합
Softmax 분류기	Dense layer 없이 바로 연결, 클래스 수 = N



Materials and Methods

EEGNet 성능 평가를 위한 두 가지 실험 방식

1. Within-subject classification

한 사람의 데이터를 그 사람 전용 모델로 학습

일반적으로 성능이 더 높음

2. Cross- subject classification

다른 피험자들의 데이터로 학습, 테스트 대상은 학습에 포함 X

일반화된 모델 생성이 목적



Materials and Methods

Within-subject 실험 방법

- 4-fold blockwise cross-validation
전체 데이터를 4개 블록으로 나눔
훈련: 2블록 / 검증: 1블록 / 테스트: 1블록
- 통계 분석: Repeated-measures ANOVA
AUC(P300, MRCP, ERN), Accuracy(SMR)



Materials and Methods

Cross-subject 실험 방법

P300 / MRCP:

랜덤으로 4명 : 검증, 1명 : 테스트, 나머지 : 학습

총 30회 반복 => 30가지 fold 생성

통계 분석: One-way ANOVA

ERN:

Kaggle competition의 10명 test set을 고정으로 사용

나머지 사람들 중 학습/검증을 반복하며 30개 fold 생성

SMR:

완전한 cross-subject 구조 강제 적용

각 테스트:

나머지 피험자 중 5명 : 학습

남은 3명 : 검증

테스트 세트는 원래 competition의 test set 유지

모든 피험자에 대해 10회 반복 → 총 90개 fold 생성

통계 분석은 within-subject와 동일한 방식 (Repeated-measures ANOVA)



Materials and Methods

클래스 불균형(class imbalance) 보정

- Loss function에 class-weight 적용 (imbalance가 존재할 때만)
- P300과 ERN에만 적용 (SMR, MRCP는 불균형 없음)
- class-weight = 반비례 가중치 방식

예: P300의 경우, 비표적 : 표적 = 5.6:1


→ 비표적 = 1, 표적 = 6 (소수점은 올림)

- 원래 EEGNet의 temporal 커널은 64 samples
- SMR 데이터는 4Hz high-pass filter가 적용되어 있어
→ temporal kernel을 32 samples로 축소 설정 (고주파에 집중)



Results

Within-subject 실험



EEGNet-4,2 vs EEGNet-8,2

모든 데이터셋에서 통계적으로 유의미한 차이 없음 ($p > 0.05$)

→ 모델 복잡도 증가가 성능 향상으로 이어지지 않음

P300

모든 CNN 기반 모델 > xDAWN+RG ($p < 0.05$)

CNN 모델들 간에는 유의미한 성능 차이 없음

MRCP

가장 큰 성능 차이가 나타남

EEGNet-4,2와 EEGNet-8,2가 모두

DeepConvNet, ShallowConvNet, xDAWN+RG보다 유의미하게 높은 성능 ($p < 0.05$)

ERN

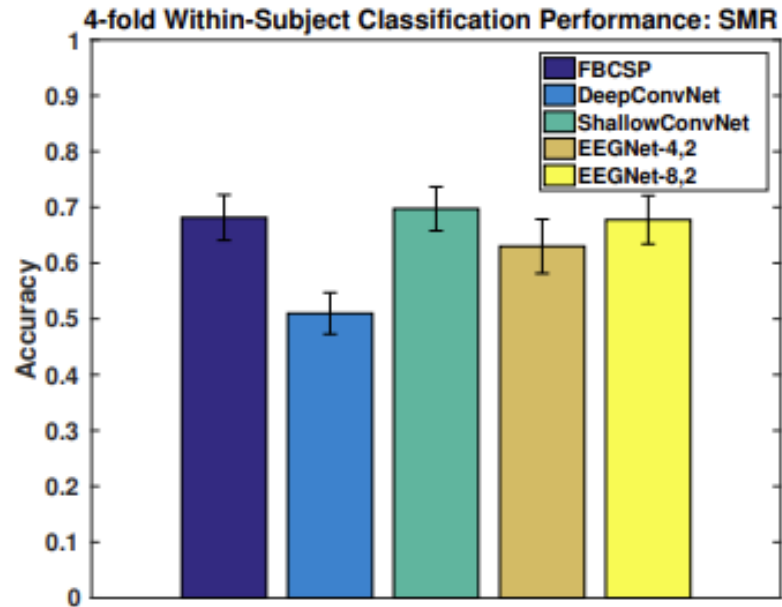
EEGNet-8,2 > DeepConvNet, ShallowConvNet, xDAWN+RG ($p < 0.05$)

EEGNet-4,2 > DeepConvNet, ShallowConvNet ($p < 0.05$)



Results

Within-subject 실험




ShallowConvNet \approx FBCSP (이전 연구 결과 재현됨)

DeepConvNet 성능이 가장 낮음 ($p < 0.05$)

EEGNet-8,2 \approx FBCSP \rightarrow EEGNet도 전통적 방법 수준의 성능 달성



Cross-subject 실험



EEGNet-4,2 vs EEGNet-8,2

모든 데이터셋에서 두 모델 간 통계적으로 유의미한 차이 없음 ($p > 0.05$)

P300

모든 CNN 기반 모델이 xDAWN + RG보다 우수함 ($p < 0.05$)

EEGNet과 DeepConvNet은 유사한 성능

ShallowConvNet은 상대적으로 낮은 성능

MRCP

EEGNet-8,2와 DeepConvNet이 ShallowConvNet보다

유의미하게 우수 ($p < 0.05$)

CNN 모델들이 within-subject보다 cross-subject에서 더 좋은 성능을 보임


ERN

기존 알고리즘 xDAWN + RG가 모든 CNN 모델보다 성능 우수 ($p < 0.05$)

CNN 기반 모델들 간에는 유의미한 성능 차이 없음



Cross-subject 실험



EEGNet-4,2, EEGNet-8,2, DeepConvNet, ShallowConvNet은 모두 비슷한 성능
모두 기존 알고리즘인 FBCSP보다 약간 더 우수
하지만 CNN 모델들 간에는 통계적으로 유의미한 성능 차이 없음 ($p > 0.05$)